



第3章 线性模型

王博：自动化（人工智能）学院
wangbo@hdu.edu.cn



目录

线性回归

- 最小二乘法

二分类任务

- 对数几率回归
- 线性判别分析

多分类任务

- 一对一
- 一对其余
- 多对多

类别不平衡问题



基本形式

线性模型一般形式

$$f(\mathbf{x}) = w_1x_1 + w_2x_2 + \dots + w_dx_d + b$$

$$\mathbf{x} = (x_1; x_2; \dots; x_d)$$

是由属性描述的示例，其中 x_i 是 \mathbf{x} 在第 i 个属性上的取值

向量形式

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

其中 $\mathbf{w} = (w_1; w_2; \dots; w_d)$



线性模型优点

形式简单、易于建模

可解释性

非线性模型的基础

➤ 引入层级结构或高维映射

一个例子

$$f_{\text{好瓜}}(\mathbf{x}) = 0.2 \cdot x_{\text{色泽}} + 0.5 \cdot x_{\text{根蒂}} + 0.3 \cdot x_{\text{敲声}} + 1$$

- 综合考虑色泽、根蒂和敲声来判断西瓜好不好
- 其中根蒂的系数最大，表明根蒂最要紧；而敲声的系数比色泽大，说明敲声比色泽更重要



线性回归

给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$

其中 $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$ $y_i \in \mathbb{R}$

线性回归 (linear regression) 目的

- 学得一个线性模型以尽可能准确地预测实值输出标记

离散属性处理

- 有“序”关系
 - 连续化为连续值
- 无“序”关系
 - 有k个属性值，则转换为k维向量



线性回归

单一属性的线性回归目标

$$f(x) = wx_i + b \quad \text{使得} \quad f(x_i) \simeq y_i$$

参数/模型估计：最小二乘法 (least square method)

$$\begin{aligned} (w^*, b^*) &= \arg \min_{(w, b)} \sum_{i=1}^m (f(x_i) - y_i)^2 \\ &= \arg \min_{(w, b)} \sum_{i=1}^m (y_i - wx_i - b)^2 \end{aligned}$$



线性回归 – 最小二乘法

最小化均方误差

$$E_{(w,b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$$

分别对 w 和 b 求导，可得

$$\frac{\partial E_{(w,b)}}{\partial w} = 2 \left(w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i \right)$$

$$\frac{\partial E_{(w,b)}}{\partial b} = 2 \left(mb - \sum_{i=1}^m (y_i - wx_i) \right)$$



线性回归 – 最小二乘法

闭式 (closed-form) 解

$$w = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} \left(\sum_{i=1}^m x_i \right)^2}$$

$$b = \frac{1}{m} \sum_{i=1}^m (y_i - wx_i)$$

其中

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$



多元线性回归

给定数据集

$$D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$$

$$\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id}) \quad y_i \in \mathbb{R}$$

多元线性回归目标

$$f(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i + b \quad \text{使得} \quad f(\mathbf{x}_i) \simeq y_i$$



多元线性回归

把 \mathbf{w} 和 b 吸收入向量形式 $\hat{\mathbf{w}} = (\mathbf{w}; b)$ 数据集表示为

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \mathbf{x}_1^T & 1 \\ \mathbf{x}_2^T & 1 \\ \vdots & \vdots \\ \mathbf{x}_m^T & 1 \end{pmatrix}$$

$$\mathbf{y} = (y_1; y_2; \dots; y_m)$$



多元线性回归 – 最小二乘法

最小二乘法 (least square method)

$$\hat{\mathbf{w}}^* = \arg \min_{\hat{\mathbf{w}}} (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}^T) (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})$$

令 $E_{\hat{\mathbf{w}}} = (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})^T (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})$, 对 $\hat{\mathbf{w}}$ 求导得到

$$\frac{\partial E_{\hat{\mathbf{w}}}}{\partial \hat{\mathbf{w}}} = 2\mathbf{X}^T (\mathbf{X}\hat{\mathbf{w}} - \mathbf{y})$$

令上式为零可得 $\hat{\mathbf{w}}$ 最优解的闭式解



多元线性回归-满秩讨论

$\mathbf{X}^T \mathbf{X}$ 是满秩矩阵或正定矩阵，则

$$\hat{\mathbf{w}}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

其中 $(\mathbf{X}^T \mathbf{X})^{-1}$ 是 $\mathbf{X}^T \mathbf{X}$ 的逆矩阵。

令 $\hat{\mathbf{x}}_i = (x_i; 1)$ ，线性回归模型为

$$f(\hat{\mathbf{x}}_i) = \hat{\mathbf{x}}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$


$\mathbf{X}^T \mathbf{X}$ 不是满秩矩阵

- 根据归纳偏好选择解
- 引入正则化



对数线性回归

输出标记的**对数**为线性模型逼近的目标



$$\ln y = w^T x + b$$



$$y = w^T x + b$$



线性回归-广义线性模型

一般形式

$$y = g^{-1}(\boldsymbol{w}^T \boldsymbol{x} + b)$$

$g(\cdot)$ 称为联系（**联结**）函数（link function）

➤ 单调可微函数

对数线性回归是 $g(\cdot) = \ln(\cdot)$ 时广义线性模型的特例



二分类任务

预测值与输出标记

$$z = \mathbf{w}^T \mathbf{x} + b \quad y \in \{0, 1\}$$

寻找函数将分类标记与线性回归模型输出联系起来

最理想的函数——单位阶跃函数

$$y = \begin{cases} 0, & z < 0; \\ 0.5, & z = 0; \\ 1, & z > 0, \end{cases}$$

- 预测值大于零就判为正例，小于零就判为反例，预测值为临界值零则可任意判别



二分类任务

单位阶跃函数缺点


➤ 不连续

替代函数——对数几率函数 (logistic function) Sigmoid 函数

单调可微、任意阶可导

$$y = \frac{1}{1 + e^{-z}}$$

单位阶跃函数与对数几率函数的比较





对数几率回归

运用对数几率函数

$$y = \frac{1}{1 + e^{-z}} \quad \text{变为} \quad y = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}}$$

对数几率 (log odds)

- 样本作为正例的相对可能性的对数

$$\ln \frac{y}{1 - y} = z = \mathbf{w}^T \mathbf{x} + b$$

对数几率回归优点

- 无需事先假设数据分布
- 可得到“类别”的近似概率预测
- 可直接应用现有数值优化算法求取最优解



对数几率回归-极大似然法

对数几率

$$\ln \frac{p(y = 1 \mid \mathbf{x})}{p(y = 0 \mid \mathbf{x})} = \mathbf{w}^T \mathbf{x} + b$$

显然有

$$p(y = 1 \mid \mathbf{x}) = \frac{e^{\mathbf{w}^T \mathbf{x} + b}}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$

$$p(y = 0 \mid \mathbf{x}) = \frac{1}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$



对数几率回归 – 极大似然法

极大似然法 (maximum likelihood)

- 给定数据集

$$\{(\mathbf{x}_i, y_i)\}_{i=1}^m$$

- 最大化样本属于其真实标记的概率
 - 最大化对数似然函数

$$\ell(\mathbf{w}, b) = \sum_{i=1}^m \ln p(y_i \mid \mathbf{x}_i; \mathbf{w}_i, b)$$



对数几率回归 – 极大似然法

转化为最小化负对数似然函数求解

➤ 令 $\beta = (w; b)$, $\hat{x} = (x; 1)$, 则 $w^T x + b$ 可简写为 $\beta^T \hat{x}$

➤ 再令 $p_1(\hat{x}_i; \beta) = p(y = 1 \mid \hat{x}_i; \beta)$

$$p_0(\hat{x}_i; \beta) = p(y = 0 \mid \hat{x}_i; \beta) = 1 - p_1(\hat{x}_i; \beta)$$

$$p(y_i \mid x_i; w_i, b) = y_i p_1(\hat{x}_i; \beta) + (1 - y_i) p_0(\hat{x}_i; \beta)$$

则似然项可重写为

$$\ell(\beta) = \sum_{i=1}^m \left(-y_i \beta^T \hat{x}_i + \ln \left(1 + e^{\beta^T \hat{x}_i} \right) \right) \quad \leftarrow$$

$$p(y = 1 \mid x) = \frac{e^{w^T x + b}}{1 + e^{w^T x + b}}$$

$$p(y = 0 \mid x) = \frac{1}{1 + e^{w^T x + b}}$$



对数几率回归

求解得

$$\boldsymbol{\beta}^* = \arg \min_{\boldsymbol{\beta}} \ell(\boldsymbol{\beta})$$

牛顿法第 $t+1$ 轮迭代解的更新公式

$$\boldsymbol{\beta}^{t+1} = \boldsymbol{\beta}^t - \left(\frac{\partial^2 \ell(\boldsymbol{\beta})}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^T} \right)^{-1} \frac{\partial \ell(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}}$$

其中关于 $\boldsymbol{\beta}$ 的一阶、二阶导数分别为

$$\frac{\partial \ell(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = - \sum_{i=1}^m \hat{\mathbf{x}}_i (y_i - p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}))$$


$$\frac{\partial^2 \ell(\boldsymbol{\beta})}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^T} = \sum_{i=1}^m \hat{\mathbf{x}}_i \hat{\mathbf{x}}_i^T p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}) (1 - p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}))$$

高阶可导连续凸函数，梯度下降法/牛顿法 [Boyd and Vandenberghe, 2004]



二分类任务 - 线性判别分析

线性判别分析 (Linear Discriminant Analysis) [Fisher, 1936]



LDA也可被视为一种
监督降维技术



二分类任务 - 线性判别分析

n维随机向量X的协方差

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{bmatrix}$$

并且 μ_i 是 X_i 的期望值, 即, $\mu_i = E(X_i)$ 。协方差矩阵的第 (i, j) 项 (第 (i, j) 项是一个协方差) 被定义为如下形式:

$$\Sigma_{ij} = \text{cov}(X_i, X_j) = E[(X_i - \mu_i)(X_j - \mu_j)]$$

而协方差矩阵为:

$$\begin{aligned} \Sigma &= E[(\mathbf{X} - E[\mathbf{X}])(\mathbf{X} - E[\mathbf{X}])^T] \\ &= \begin{bmatrix} E[(X_1 - \mu_1)(X_1 - \mu_1)] & E[(X_1 - \mu_1)(X_2 - \mu_2)] & \cdots & E[(X_1 - \mu_1)(X_n - \mu_n)] \\ E[(X_2 - \mu_2)(X_1 - \mu_1)] & E[(X_2 - \mu_2)(X_2 - \mu_2)] & \cdots & E[(X_2 - \mu_2)(X_n - \mu_n)] \\ \vdots & \vdots & \ddots & \vdots \\ E[(X_n - \mu_n)(X_1 - \mu_1)] & E[(X_n - \mu_n)(X_2 - \mu_2)] & \cdots & E[(X_n - \mu_n)(X_n - \mu_n)] \end{bmatrix} \end{aligned}$$



二分类任务 - 线性判别分析

样本实现协方差的估计

设 X_1, X_2, \dots, X_n 为一组随机变量, 记 $X = (X_1, X_2, \dots, X_n)^T$ 为由这 n 个随机变量构成的随机向量. 假设每个随机变量有 m 个样本, 将所有样本拼在一起可得如下样本矩阵

$$S = \begin{bmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,m} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,m} \\ & & \ddots & \\ x_{n,1} & x_{n,2} & \cdots & x_{n,m} \end{bmatrix}_{n \times m}$$

列表示样
本数目

$$E(X_i) = \frac{1}{m} \sum_{k=1}^m x_{i,k}, \quad E(X_j) = \frac{1}{m} \sum_{k=1}^m x_{j,k},$$



二分类任务 - 线性判别分析

样本实现协方差的估计

$$Y_k = (x_{ik} - E(X_i))(x_{jk} - E(X_j)), \quad k = 1, 2, \dots, m.$$

$$\begin{aligned} c_{i,j} &= E(Y) = \frac{1}{m} \sum_{k=1}^m Y_k \\ &= \frac{1}{m} \sum_{k=1}^m (x_{i,k} - E(X_i))(x_{j,k} - E(X_j)) \\ &= \frac{1}{m} \sum_{k=1}^m \left[(x_{i,k} - \frac{1}{m} \sum_{p=1}^m x_{i,p})(x_{j,k} - \frac{1}{m} \sum_{q=1}^m x_{j,q}) \right]. \end{aligned}$$

多元高斯分布

$$f_{\mathbf{x}}(x_1, \dots, x_k) = \frac{1}{\sqrt{(2\pi)^k |\Sigma|}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x}-\boldsymbol{\mu})},$$

注意这里的 $|\Sigma|$ 表示协方差矩阵的行列式。



二分类任务 - 线性判别分析

LDA的思想

- 欲使同类样例的投影点尽可能接近，可以让同类样例投影点的协方差尽可能小
- 欲使异类样例的投影点尽可能远离，可以让类中心之间的距离尽可能大

一些变量

- 第 i 类示例的集合 X_i
- 第 i 类示例的均值向量 μ_i
- 第 i 类示例的协方差矩阵 Σ_i
- 两类样本的中心在直线上的投影: $w^T \mu_0$ 和 $w^T \mu_1$
- 两类样本的协方差: $w^T \Sigma_0 w$ 和 $w^T \Sigma_1 w$



二分类任务 - 线性判别分析

最大化目标（不同类中心尽可能远，同类尽可能近）

$$\begin{aligned} J &= \frac{\|w^T \mu_0 - w^T \mu_1\|_2^2}{w^T \Sigma_0 w + w^T \Sigma_1 w} \\ &= \frac{w^T (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T w}{w^T (\Sigma_0 + \Sigma_1) w} \end{aligned}$$

类内散度矩阵：类内散度矩阵用于表示样本点围绕均值的散步情况

$$\begin{aligned} S_w &= \Sigma_0 + \Sigma_1 \\ &= \sum_{x \in X_0} (x - \mu_0) (x - \mu_0)^T + \sum_{x \in X_1} (x - \mu_1) (x - \mu_1)^T \end{aligned}$$

类间散度矩阵

$$S_b = (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T$$



二分类任务 - 线性判别分析

广义瑞利商 (generalized Rayleigh quotient)

$$J = \frac{\mathbf{w}^T \mathbf{S}_b \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}}$$

令 $\mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1$ ，最大化广义瑞利商等价形式为

$$\begin{aligned} \min_{\mathbf{w}} \quad & -\mathbf{w}^T \mathbf{S}_b \mathbf{w} \\ \text{s.t.} \quad & \mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1 \end{aligned}$$

运用拉格朗日乘子法

$$\mathbf{S}_b \mathbf{w} = \lambda \mathbf{S}_w \mathbf{w}$$



二分类任务 - 线性判别分析

同向向量

$$\underline{S_b w} = \lambda (\underline{\mu_0 - \mu_1})$$

同向向量

结果

$$w = S_w^{-1} (\mu_0 - \mu_1)$$

求解

➤ 奇异值分解 $S_w = U \Sigma V^T$



LDA推广 - 多分类任务

全局散度矩阵

$$\begin{aligned} S_t &= S_b + S_w \\ &= \sum_{i=1}^m (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T \end{aligned}$$

类内散度矩阵

$$S_w = \sum_{i=1}^N S_{w_i} \quad S_{w_i} = \sum_{\mathbf{x} \in X_i} (\mathbf{x} - \boldsymbol{\mu}_i)(\mathbf{x} - \boldsymbol{\mu}_i)^T$$

求解得

$$\begin{aligned} S_b &= S_t - S_w \\ &= \sum_{i=1}^N m_i (\boldsymbol{\mu}_i - \boldsymbol{\mu})(\boldsymbol{\mu}_i - \boldsymbol{\mu})^T \end{aligned}$$



LDA推广 - 多分类任务

优化目标

$$\max_{\mathbf{W}} \frac{\text{tr}(\mathbf{W}^T \mathbf{S}_b \mathbf{W})}{\text{tr}(\mathbf{W}^T \mathbf{S}_w \mathbf{W})} \quad \mathbf{W} \in \mathbb{R}^{d \times (N-1)}$$

求解 $\mathbf{S}_b \mathbf{W} = \lambda \mathbf{S}_w \mathbf{W}$

\mathbf{W} 闭式解则是 $\mathbf{S}_w^{-1} \mathbf{S}_b$ 的 $N-1$ 个最大广义特征值所对应的特征向量组成的矩阵

多分类LDA将样本投影到 $N-1$ 维空间, $N-1$ 通常远小于数据原有的维数, 因此LDA也被视为一种监督降维技术



多分类学习

多分类学习方法

- 二分类学习方法推广到多类
- 利用二分类学习器解决多分类问题 (常用)
 - 对问题进行拆分, 为拆出的每个二分类任务训练一个分类器
 - 对于每个分类器的预测结果进行集成以获得最终的多分类结果

拆分策略

- 一对一 (One vs. One, OvO)
- 一对其余 (One vs. Rest, OvR)
- 多对多 (Many vs. Many, MvM)



多分类学习 - 一对一

拆分阶段

- N个类别两两配对
 - $N(N-1)/2$ 个二类任务
- 各个二类任务学习分类器
 - $N(N-1)/2$ 个二类分类器

测试阶段

- 新样本提交给所有分类器预测
 - $N(N-1)/2$ 个分类结果
- 投票产生最终分类结果
 - 被预测最多的类别为最终类别



多分类学习 - 一对其余

任务拆分

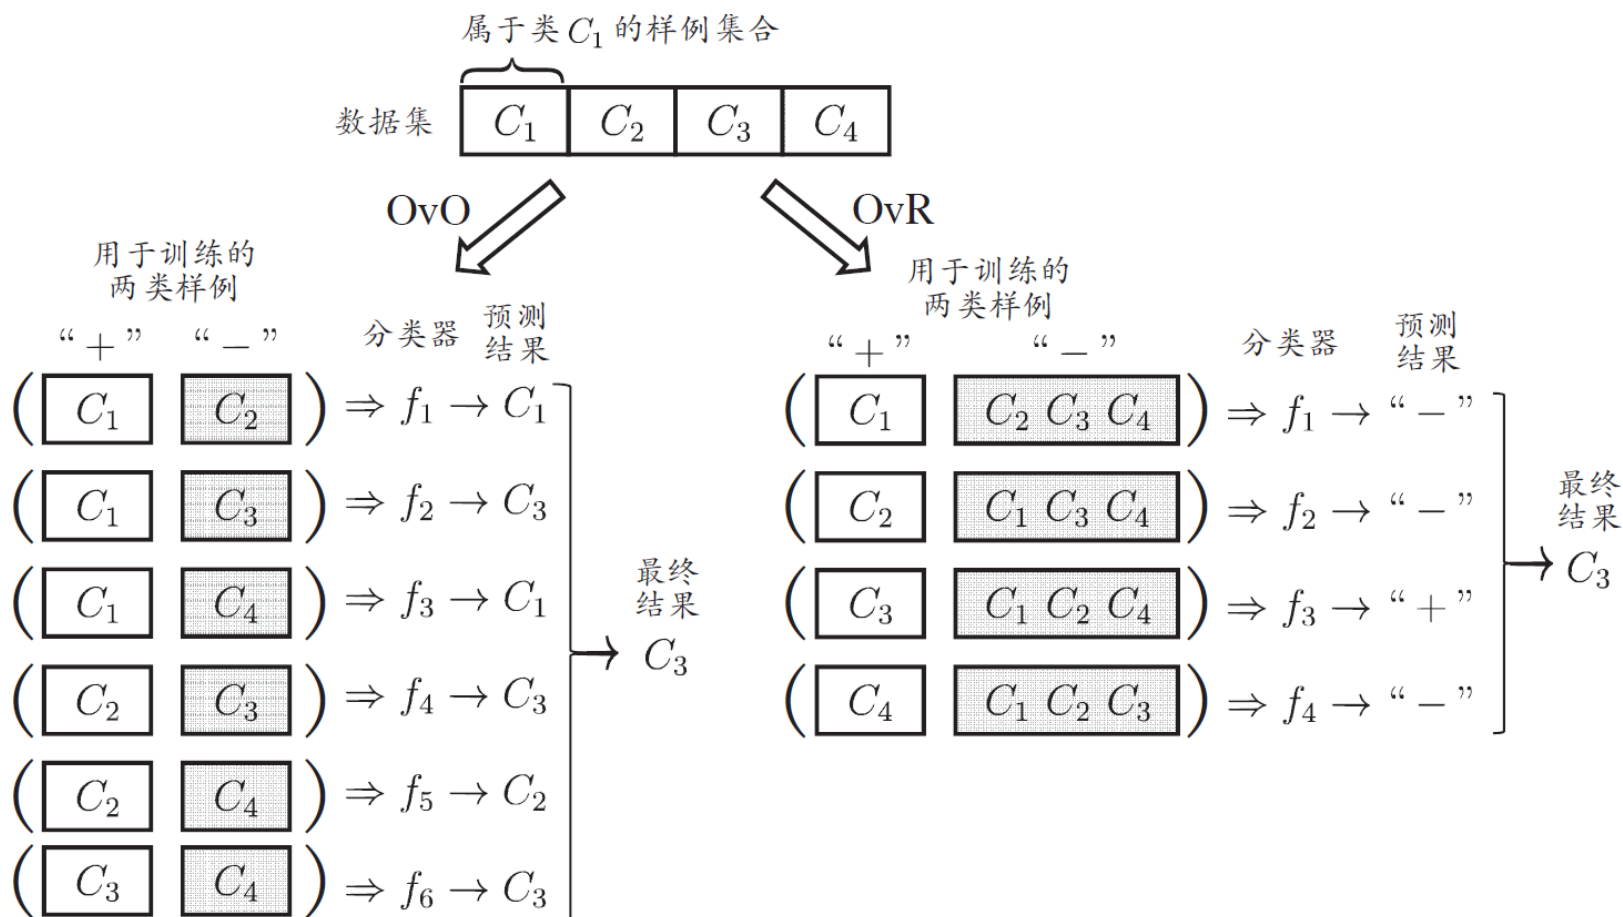
- 某一类作为正例，其他反例
 - N 个二类任务
- 各个二类任务学习分类器
 - N 个二类分类器

测试阶段

- 新样本提交给所有分类器预测
 - N 个分类结果
- 比较各分类器预测置信度
 - 置信度最大类别作为最终类别



多分类学习 - 两种策略比较





多分类学习 - 两种策略比较

一对一

- 训练 $N(N-1)/2$ 个分类器，存储开销和测试时间大
- 训练只用两个类的样例，训练时间短

一对其余

- 训练 N 个分类器，存储开销和测试时间小
- 训练用到全部训练样例，训练时间长

预测性能取决于具体数据分布，多数情况下两者差不多



多分类学习 - 多对多

多对多 (Many vs Many, MvM)

- 若干类作为正类，若干类作为反类
- 纠错输出码 (Error Correcting Output Code, ECOC)

编码：对N个类别做M次划分，
每次划分将一部分类别划为正
类，一部分划为反类

解码：测试样本交给M个分类
器预测

M个二类任务
各个类别长度为M的编码

距离最小的类别为
最终类别

长度为M的编码预测





多分类学习 - 多对多

纠错输出码 (Error Correcting Output Code, ECOC)

	f_1	f_2	f_3	f_4	f_5	海明距离	欧氏距离
	↓	↓	↓	↓	↓	↓	↓
$C_1 \rightarrow$	-1	+1	-1	+1	+1	3	$2\sqrt{3}$
$C_2 \rightarrow$	+1	-1	-1	+1	-1	4	4
$C_3 \rightarrow$	-1	+1	+1	-1	+1	1	2
$C_4 \rightarrow$	-1	-1	+1	+1	-1	2	$2\sqrt{2}$
测试示例 \rightarrow	-1	-1	+1	-1	+1	↑	↑

(a) 二元 ECOC 码

[Dietterich and Bakiri, 1995]

	f_1	f_2	f_3	f_4	f_5	f_6	f_7	海明距离	欧氏距离
	↓	↓	↓	↓	↓	↓	↓	↓	↓
$C_1 \rightarrow$	-1	-1	+1	+1	-1	+1	+1	4	4
$C_2 \rightarrow$	-1	0	0	0	+1	-1	0	2	2
$C_3 \rightarrow$	+1	+1	-1	-1	-1	+1	-1	5	$2\sqrt{5}$
$C_4 \rightarrow$	-1	+1	0	+1	-1	0	+1	3	$\sqrt{10}$
测试示例 \rightarrow	-1	+1	+1	-1	+1	-1	+1	↑	↑

(b) 三元 ECOC 码

[Allwein et al. 2000]

- ECOC编码对分类器错误有一定容忍和修正能力，编码越长、纠错能力越强
- 对同等长度的编码，理论上来说，任意两个类别之间的编码距离越远，则纠错能力越强



类别不平衡问题

类别不平衡 (class imbalance)

- 不同类别训练样例数相差很大情况 (正类为小类)

类别平衡正例预测 $\frac{y}{1-y} > 1$  $\frac{y}{1-y} > \frac{m^+}{m^-}$ 正负类比例

再缩放

- 欠采样 (undersampling)
 - 去除一些反例使正反例数目接近 (EasyEnsemble [Liu et al., 2009])
- 过采样 (oversampling)
 - 增加一些正例使正反例数目接近 (SMOTE [Chawla et al. 2002])
- 阈值移动 (threshold-moving)



优化提要

各任务下（回归、分类）各个模型优化的目标

- 最小二乘法：最小化均方误差
- 对数几率回归：最大化样本分布似然
- 线性判别分析：投影空间内最小（大）化类内（间）散度

参数的优化方法

- 最小二乘法：线性代数
- 对数几率回归：凸优化梯度下降、牛顿法
- 线性判别分析：矩阵论、广义瑞利商



总结

线性回归

- 最小二乘法（最小化均方误差）

二分类任务

- 对数几率回归
 - 单位阶跃函数、对数几率函数、极大似然法
- 线性判别分析
 - 最大化广义瑞利商

多分类学习

- 一对一
- 一对其余
- 多对多
 - 纠错输出码

类别不平衡问题

- 基本策略：再缩放