



第6章 支持向量机

王博：自动化（人工智能）学院
wangbo@hdu.edu.cn



章节目录

- 间隔与支持向量
 - 对偶问题
 - 核函数
 - 软间隔与正则化
 - 支持向量回归
 - 核方法
-




章节目录

- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归
- 核方法



间隔与支持向量


线性模型：在样本空间中寻找一个超平面，将不同类别的样本分开。





间隔与支持向量


Q:将训练样本分开的超平面可能有很多, 哪一个好呢?





间隔与支持向量

Q:将训练样本分开的超平面可能有很多, 哪一个好呢?



A:应选择”正中间”, 容忍性好, 鲁棒性高, 泛化能力最强.



间隔与支持向量


超平面方程: $w^\top x + b = 0$

点到平面的距离:

$$x = x_0 + \gamma \frac{w}{\|w\|}$$



$$\gamma = \frac{w^\top x + b}{\|w\|} = \frac{f(x)}{\|w\|}$$





间隔与支持向量

超平面方程: $w^\top x + b = 0$


假设线性可分下引入间隔 y 为标签:

$$\tilde{\gamma} = y\gamma = \frac{\hat{\gamma}}{\|w\|}$$

目标函数为:

$$\max \tilde{\gamma}$$

$$s.t., y_i(w^\top x_i + b) = \hat{\gamma}_i \geq \hat{\gamma}, \quad i = 1, \dots, n$$





支持向量机基本型

最大间隔: 寻找参数 \mathbf{w} 和 b , 使得 γ 最大.

$$\begin{aligned} \arg \max_{\mathbf{w}, b} \quad & \frac{2}{\|\mathbf{w}\|} \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$



$$\begin{aligned} \arg \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$

凸优化: 凸集上的凸函数的最小化问题



章节目录

- 间隔与支持向量
 - 对偶问题
 - 核函数
 - 软间隔与正则化
 - 支持向量回归
 - 核方法
-



对偶问题

- 标准优化问题，假定目标函数及约束函数都是可微的：

$$\begin{aligned} \min_{\mathbf{x}} \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & f_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m \\ & h_i(\mathbf{x}) = 0, \quad i = 1, \dots, p \end{aligned}$$

- 拉格朗日函数：

$$L(\mathbf{x}, \lambda, \nu) = f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{i=1}^p \nu_i h_i(\mathbf{x})$$

其中， $\lambda_i \geq 0$ ， ν_i 分别为不等式约束和等式约束的拉格朗日乘子



对偶问题

➤ 拉格朗日对偶函数:

$$g(\lambda, \nu) = \inf_{\mathbf{x} \in \mathcal{D}} L(\mathbf{x}, \lambda, \nu)$$

其中 $\lambda = [\lambda_1, \dots, \lambda_m]^T$ 和 $\nu = [\nu_1, \dots, \nu_p]^T$

➤ 对偶问题:

$$\begin{aligned} \max_{\lambda, \nu} & g(\lambda, \nu) \\ \text{s.t. } & \lambda \succeq \mathbf{0} \end{aligned}$$



KKT条件

记 \mathbf{x}^* 和 (λ^*, ν^*) 分别是原问题和对偶问题的一对最优解

假设**强对偶性成立**(原对偶问题有相同的最优值), 则有
如下一组重要的结论

$$f_i(\mathbf{x}^*) \leq 0, i = 1, \dots, m$$

$$h_i(\mathbf{x}^*) = 0, i = 1, \dots, p$$

$$\lambda_i^* \geq 0, i = 1, \dots, m$$

$$\lambda_i^* f_i(\mathbf{x}^*) = 0, i = 1, \dots, m$$

$$\nabla f_0(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(\mathbf{x}^*) + \sum_{i=1}^p \nu_i^* \nabla h_i(\mathbf{x}^*) = \mathbf{0}$$

KKT条件是最优解的必要条件。

若**原问题为凸优化问题**, 且目标函数和约束函数可微,

KKT条件也是充分条件。



对偶问题

➤ 目标函数:

$$\min \frac{1}{2} \|w\|^2 \quad s.t., y_i(w^T x_i + b) \geq 1, i = 1, \dots, n$$

➤ 拉格朗日乘法:

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i(w^T x_i + b) - 1)$$

➤ 引入函数:

$$\theta(w) = \max_{\alpha_i \geq 0} \mathcal{L}(w, b, \alpha)$$

➤ 原目标函数变成:

$$\min_{w, b} \theta(w) = \min_{w, b} \max_{\alpha_i \geq 0} \mathcal{L}(w, b, \alpha) = p^*$$

➤ 对偶问题:

$$\max_{\alpha_i \geq 0} \min_{w, b} \mathcal{L}(w, b, \alpha) = d^*$$



对偶问题

➤ 对偶函数: $\max_{\alpha_i \geq 0} \min_{w, b} \mathcal{L}(w, b, \alpha) = d^*$

➤ 首先 $\mathcal{L}(w, b, \alpha)$ 关于 w 和 b 最小化

$$\frac{\partial \mathcal{L}}{\partial w} = 0 \Rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\frac{\partial \mathcal{L}}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

➤ 代入 $\mathcal{L}(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1)$

$$\begin{aligned} \mathcal{L}(w, b, \alpha) &= \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j b - b \sum_{i=1}^n \alpha_i y_i + \sum_{i=1}^n \alpha_i \\ &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \end{aligned}$$



对偶问题

➤ 原问题:

$$\min \frac{1}{2} \|w\|^2 \quad s.t., y_i(w^T x_i + b) \geq 1, i = 1, \dots, n$$

➤ 对偶问题:

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \\ s.t. \quad & \alpha_i \geq 0, i = 1, \dots, n \\ & \sum_{i=1}^n \alpha_i y_i = 0 \end{aligned}$$



解的稀疏性

最终模型: $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^\top \mathbf{x} + b$

KKT条件:

$$\alpha_i \geq 0,$$

$$y_i f(\mathbf{x}_i) \geq 1,$$

$$\alpha_i (y_i f(\mathbf{x}_i) - 1) = 0.$$



$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i$$

$$\frac{\partial \mathcal{L}}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

$$y_i f(\mathbf{x}_i) > 1 \quad \Rightarrow \quad \alpha_i = 0$$

支持向量机解的稀疏性: 训练完成后, 大部分的训练样本都不需保留, 最终模型仅与支持向量有关.



偏移项的确定

偏移项 b ：通过支持向量来确定

任意的支持向量 (x_s, y_s) ：

$$y_s f(x_s) = 1 \Rightarrow y_s \left(\sum_{i \in S} \alpha_i y_i x_i^T x_s + b \right) = 1$$

更鲁棒的方法：

$$b = \frac{1}{|S|} \sum_{s \in S} (y_s - \sum_{i \in S} \alpha_i y_i x_i^T x_s)$$



章节目录


- 间隔与支持向量
- 对偶问题
- **核函数**
- 软间隔与正则化
- 支持向量回归
- 核方法



线性不可分

Q: 若不存在一个能正确划分两类样本的超平面, 怎么办?

A: 将样本从原始空间映射到一个更高维的特征空间, 使得样本在这个特征空间内线性可分.



异或问题与非线性映射



核支持向量机

设样本 \mathbf{x} 映射后的向量为 $\phi(\mathbf{x})$, 划分超平面为 $f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b$

原始问题:
$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$
$$\text{s.t. } y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b) \geq 1, \quad i = 1, 2, \dots, m.$$

对偶问题:
$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$$
$$\text{s.t. } \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, m.$$

求解后模型:
$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m \alpha_i y_i \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}) + b$$



核函数

基本想法：不显式地设计核映射, 而是**设计核函数**.

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$$

定义 核函数[2] 设 \mathcal{X} 是输入空间 (即 $x_i \in \mathcal{X}$, \mathcal{X} 是 \mathbb{R}^n 的子集或离散集合), 又设 \mathcal{H} 为特征空间 (\mathcal{H} 是希尔伯特空间[3]), 如果存在一个从 \mathcal{X} 到 \mathcal{H} 的映射

$$\phi(x) : \mathcal{X} \rightarrow \mathcal{H}$$

使得对所有 $x, z \in \mathcal{X}$, 函数 $K(x, z)$ 满足条件

$$K(x, z) = \langle \phi(x), \phi(z) \rangle$$

则称 K 为核函数。其中 $\phi(x)$ 为映射函数, $\langle \cdot, \cdot \rangle$ 为内积。



核函数

定理 6.1 (核函数) 令 \mathcal{X} 为输入空间, $\kappa(\cdot, \cdot)$ 是定义在 $\mathcal{X} \times \mathcal{X}$ 上的对称函数, 则 κ 是核函数当且仅当对于任意数据 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$, “核矩阵” (kernel matrix) \mathbf{K} 总是半正定的:

$$\mathbf{K} = \begin{bmatrix} \kappa(\mathbf{x}_1, \mathbf{x}_1) & \cdots & \kappa(\mathbf{x}_1, \mathbf{x}_j) & \cdots & \kappa(\mathbf{x}_1, \mathbf{x}_m) \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ \kappa(\mathbf{x}_i, \mathbf{x}_1) & \cdots & \kappa(\mathbf{x}_i, \mathbf{x}_j) & \cdots & \kappa(\mathbf{x}_i, \mathbf{x}_m) \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ \kappa(\mathbf{x}_m, \mathbf{x}_1) & \cdots & \kappa(\mathbf{x}_m, \mathbf{x}_j) & \cdots & \kappa(\mathbf{x}_m, \mathbf{x}_m) \end{bmatrix}.$$



核函数

常用核函数：

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\delta^2}\right)$	$\delta > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\delta}\right)$	$\delta > 0$
Sigmoid核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$	\tanh 为双曲正切函数, $\beta > 0, \theta < 0$



章节目录


- 间隔与支持向量
 - 对偶问题
 - 核函数
 - **软间隔与正则化**
 - 支持向量回归
 - 核方法
-



软间隔

Q:现实中, 很难确定合适的核函数使得训练样本在特征空间中**线性可分**; 同时一个线性可分的结果也很难断定是否是有**过拟合**造成的。

A:引入**“软间隔”**的概念, 允许支持向量机在一些样本上不满足约束。





0/1损失函数

基本想法：最大化间隔的同时，让不满足约束的样本应尽可能少。

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m l_{0/1} (y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b) - 1)$$

其中 $l_{0/1}$ 是“0/1损失函数”


$$l_{0/1} = \begin{cases} 1 & z < 0 \\ 0 & otherwise \end{cases}$$

存在的问题：0/1损失函数非凸、非连续，不易优化！



替代损失

软间隔SVM



“替代损失”函数数学性质较好，一般是凸的且是0/1损失函数的上界



软间隔支持向量机

采用**hinge**损失原始问题:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b)).$$

引入松弛变量 $\xi_i \geq 0$

$$\begin{aligned} \min_{\mathbf{w}, b, \xi_i} & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s.t.} & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0, i = 1, \dots, m \end{aligned}$$



软间隔支持向量机

拉格朗日函数:

$$L(w, b, \alpha, \xi, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i \\ + \sum_{i=1}^m \alpha_i (1 - \xi_i - y_i (w^T x_i + b)) - \sum_{i=1}^m \mu_i \xi_i$$

$L(w, b, \alpha, \xi, \mu)$ 对 w, b, ξ_i 求偏导

$$w = \sum_{i=1}^m \alpha_i y_i x_i ,$$

$$0 = \sum_{i=1}^m \alpha_i y_i ,$$

$$C = \alpha_i + \mu_i .$$



软间隔支持向量机

对偶函数:

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m. \end{aligned}$$

KKT条件:

$$\begin{aligned} & y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i \geq 0 \\ & \xi_i \geq 0 \\ & \alpha_i \geq 0 \\ & \mu_i \geq 0 \\ & \alpha_i [y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i] = 0 \\ & \mu_i \xi_i = 0 \end{aligned} \quad + \quad \begin{aligned} & \frac{\partial L}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i = \mathbf{0} \\ & \frac{\partial L}{\partial \xi} = C \cdot \mathbf{1} - \alpha - \mu = \mathbf{0} \\ & \frac{\partial L}{\partial b} = \sum_{i=1}^N \alpha_i y_i = \alpha^T \mathbf{y} = 0 \end{aligned}$$



软间隔支持向量机

KKT条件

$$\begin{array}{l} y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i \geq 0 \\ \xi_i \geq 0 \\ \alpha_i \geq 0 \\ \mu_i \geq 0 \\ \alpha_i [y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i] = 0 \\ \mu_i \xi_i = 0 \end{array} \quad + \quad \begin{array}{l} \frac{\partial L}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i = \mathbf{0} \\ \frac{\partial L}{\partial \xi} = C \cdot \mathbf{1} - \alpha - \mu = \mathbf{0} \\ \frac{\partial L}{\partial b} = \sum_{i=1}^N \alpha_i y_i = \alpha^T \mathbf{y} = 0 \end{array}$$

分析：如果 $\alpha_i \in (0, C)$ $\begin{cases} y_i f(x_i) - 1 + \xi_i = 0 \\ C - \alpha_i - \mu_i = 0 \\ \mu_i \xi_i = 0 \end{cases} \Rightarrow y_i f(x_i) = 1 (\text{支持向量点})$

如果 $\alpha_i = 0$ $\begin{cases} y_i f(x_i) - 1 + \xi_i \geq 0 \\ C - \alpha_i - \mu_i = 0 \\ \mu_i \xi_i = 0 \end{cases} \Rightarrow y_i f(x_i) \geq 1$

此外 $\alpha_i = C \Leftrightarrow y_i f(x_i) \geq 1$



SMO算法

序列最小优化算法 (SMO: Sequential minimal optimization)

求解如下的最优问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1, j=1}^m \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^m \alpha_i$$

$$\text{s.t.} \quad \sum_{i=1}^m \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m.$$



SMO算法

基本思路：不断执行如下两个步骤直至收敛.

- 第一步：选取一对需更新的变量 α_i 和 α_j .
- 第二步：固定 α_i 和 α_j 以外的参数, 求解对偶问题更新 α_i 和 α_j .

仅考虑 α_i 和 α_j 时, 对偶问题的约束变为

$$\alpha_i y_i + \alpha_j y_j = - \sum_{k \neq i, j} \alpha_k y_k, \quad 0 \leq \alpha_i \leq C$$

用一个变量表示另一个变量, 回代入对偶问题可得一个单变量的二次规划, 该问题具有闭式解.



SMO算法

仅考虑 α_i 和 α_j 时，原问题可以变成只含**2**个变量的优化问题


$$\begin{aligned} \min_{\alpha_1, \alpha_2} & \frac{1}{2} K_{11} \alpha_1^2 + \frac{1}{2} K_{22} \alpha_2^2 + y_1 y_2 K_{12} \alpha_1 \alpha_2 - (\alpha_1 + \alpha_2) \\ & + y_1 \alpha_1 \sum_{i=3}^m y_i \alpha_i K_{i1} + y_2 \alpha_2 \sum_{i=3}^m y_i \alpha_i K_{i2} \\ \text{s.t. } & \alpha_1 y_1 + \alpha_2 y_2 = - \sum_{i=3}^m y_i \alpha_i = \varsigma, \quad 0 \leq \alpha_i \leq C \end{aligned}$$

其中 $K_{ij} = K(x_i, x_j)$



SMO算法

根据上面的约束条件 $\alpha_1 y_1 + \alpha_2 y_2 = \varsigma$ $0 \leq \alpha_i \leq C$ $i = 1, 2$, 又由于 y_1, y_2 均只能取值1或者-1, 这样 α_1, α_2 在 $[0, C]$ 和 $[0, C]$ 形成的盒子里面, 并且两者的关系直线的斜率只能为1或者-1, 也就是说 α_1, α_2 的关系直线平行于 $[0, C]$ 和 $[0, C]$ 形成的盒子的对角线, 如下图所示:



由于 α_1, α_2 的关系被限制在盒子里的一条线段上, 所以两变量的优化问题实际上仅仅是一个变量的优化问题。不妨我们假设最终是 α_2 的优化问题。由于我们采用的是启发式的迭代法, 假设我们上一轮迭代得到的解是 $\alpha_1^{old}, \alpha_2^{old}$, 假设沿着约束方向 α_2 未经剪辑的解是 $\alpha_2^{new, unc}$. 本轮迭代完成后的解为 $\alpha_1^{new}, \alpha_2^{new}$



SMO算法

由于 α_2^{new} 必须满足上图中的线段约束。假设L和H分别是上图中 α_2^{new} 所在的线段的边界。那么很显然我们有：

$$L \leq \alpha_2^{new} \leq H$$

而对于L和H，我们也有限制条件如果是上面左图中的情况，则

$$L = \max(0, \alpha_2^{old} - \alpha_1^{old}) \quad H = \min(C, C + \alpha_2^{old} - \alpha_1^{old})$$

如果是上面右图中的情况，我们有：

$$L = \max(0, \alpha_2^{old} + \alpha_1^{old} - C) \quad H = \min(C, \alpha_2^{old} + \alpha_1^{old})$$

也就是说，假如我们通过求导得到的 $\alpha_2^{new,unc}$ ，则最终的 α_2^{new} 应该为：

$$\alpha_2^{new} = \begin{cases} H & \alpha_2^{new,unc} > H \\ \alpha_2^{new,unc} & L \leq \alpha_2^{new,unc} \leq H \\ L & \alpha_2^{new,unc} < L \end{cases}$$



SMO算法

仅考虑 α_2 的二次规划问题，导数为0

$$\begin{aligned} E_i &= g(x_i) - y_i \\ &= \sum_{j=1}^m \alpha_j^* y_j K(x_i, x_j) + b - y_i \end{aligned}$$

定理 7.6 最优化问题沿着约束方向未经剪辑时的解是

$$\alpha_2^{\text{new,unc}} = \alpha_2^{\text{old}} + \frac{y_2(E_1 - E_2)}{\eta}$$

其中，

$$\eta = K_{11} + K_{22} - 2K_{12} = \|\Phi(x_1) - \Phi(x_2)\|^2$$

$\Phi(x)$ 是输入空间到特征空间的映射，
经剪辑后 α_2 的解是

$$\alpha_2^{\text{new}} = \begin{cases} H, & \alpha_2^{\text{new,unc}} > H \\ \alpha_2^{\text{new,unc}}, & L \leq \alpha_2^{\text{new,unc}} \leq H \\ L, & \alpha_2^{\text{new,unc}} < L \end{cases}$$

由 α_2^{new} 求得 α_1^{new} 是

$$\alpha_1^{\text{new}} = \alpha_1^{\text{old}} + y_1 y_2 (\alpha_2^{\text{old}} - \alpha_2^{\text{new}})$$



SMO-变量的选择方法

第1个变量的选择（外循环实现）：选违反KKT最严重的样本点，并将其对应的变量作为第一个变量

$$y_i g(x_i) = \begin{cases} \geq 1, \Leftrightarrow \alpha_i = 0; \\ = 1, \Leftrightarrow \alpha_i \in (0, C); \\ \leq 1, \Leftrightarrow \alpha_i = C \end{cases}$$

$$g(x_i) = \sum_{j=1}^m \alpha_j y_j K(x_i, x_j) + b$$

首先找违反 $\alpha_i \in (0, C) \Rightarrow y_i g(x_i) \leq 1$ 的点，如果都满足，再找其它情况 $\alpha_i = 0, \alpha_i = C$



SMO-变量的选择方法

第2个变量 α_2 的选择（内循环实现）：希望能使 $|E_1 - E_2|$ 有足够多的变化

由于 α_1 定了的时候, E_1 也确定了, 所以要想 $|E_1 - E_2|$ 最大

- 只需要在 E_1 为正时, 选择最小的 E_i 作为 E_2 ,
- 在 E_1 为负时, 选择最大的 E_i 作为 E_2 , 可以将所有的 E_i 保存下来加快迭代

如果内存循环找到的点不能让目标函数有足够的下降, 可以采用遍历支持向量点来做 α_2 , 直到目标函数有足够的下降, 如果所有的支持向量做 α_2 都不能让目标函数有足够的下降, 可以跳出循环, 重新选择 α_1



SMO-变量的选择方法

第2个变量 α_2 的选择（内循环实现）：希望能使 $|E_1 - E_2|$ 有足够多的变化

由于 α_1 定了的时候, E_1 也确定了, 所以要想 $|E_1 - E_2|$ 最大

- 只需要在 E_1 为正时, 选择最小的 E_i 作为 E_2 ,
- 在 E_1 为负时, 选择最大的 E_i 作为 E_2 , 可以将所有的 E_i 保存下来加快迭代

如果内存循环找到的点不能让目标函数有足够的下降, 可以采用遍历支持向量点来做 α_2 , 直到目标函数有足够的下降, 如果所有的支持向量做 α_2 都不能让目标函数有足够的下降, 可以跳出循环, 重新选择 α_1



SMO-计算偏移项 b 和偏差 E_i

在每次完成两个变量的优化之后，需要重新计算阈值 b 。当 $0 < \alpha_1^{new} < C$ 时，我们有

$$y_1 - \sum_{i=1}^m \alpha_i y_i K_{i1} - b_1 = 0$$

于是新的 b_1^{new} 为：

$$b_1^{new} = y_1 - \sum_{i=3}^m \alpha_i y_i K_{i1} - \alpha_1^{new} y_1 K_{11} - \alpha_2^{new} y_2 K_{21}$$

计算出 E_1 为：

$$E_1 = g(x_1) - y_1 = \sum_{i=3}^m \alpha_i y_i K_{i1} + \alpha_1^{old} y_1 K_{11} + \alpha_2^{old} y_2 K_{21} + b^{old} - y_1$$

可以看到上两式都有 $y_1 - \sum_{i=3}^m \alpha_i y_i K_{i1}$ ，因此可以将 b_1^{new} 用 E_1 表示为：

$$b_1^{new} = -E_1 - y_1 K_{11}(\alpha_1^{new} - \alpha_1^{old}) - y_2 K_{21}(\alpha_2^{new} - \alpha_2^{old}) + b^{old}$$



SMO-计算偏移项 b 和偏差 E_i

同样的, 如果 $0 < \alpha_2^{new} < C$, 那么有:

$$b_2^{new} = -E_2 - y_1 K_{12}(\alpha_1^{new} - \alpha_1^{old}) - y_2 K_{22}(\alpha_2^{new} - \alpha_2^{old}) + b^{old}$$

最终的 b^{new} 为:

$$b^{new} = \frac{b_1^{new} + b_2^{new}}{2}$$

得到了 b^{new} 我们需要更新 E_i :

$$E_i = \sum_S y_j \alpha_j K(x_i, x_j) + b^{new} - y_i$$

其中, S 是所有支持向量 x_j 的集合。



SMO-伪代码

输入是 m 个样本 $(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)$
 y 为二元输出, 值为1, 或者-1. 精度 ϵ .

输出是近似解 α

1) 取初值 $\alpha^0 = 0, k = 0$

2) 选择 α_1^k, α_2^k , 求出新的 $\alpha_2^{new,unc}$.

$$\alpha_2^{new,unc} = \alpha_2^k + \frac{y_2(E_1 - E_2)}{K_{11} + K_{22} - 2K_{12}}$$

3) 按照下式求出 α_2^{k+1}

$$\alpha_2^{k+1} = \begin{cases} H & \alpha_2^{new,unc} > H \\ \alpha_2^{new,unc} & L \leq \alpha_2^{new,unc} \leq H \\ L & \alpha_2^{new,unc} < L \end{cases}$$

4) 利用 α_2^{k+1} 和 α_1^{k+1} 的关系求出 α_1^{k+1}

5) 计算 b^{k+1} 和 E_i

6) 在精度 ϵ 范围内检查是否满足如下的终止条件:

$$\sum_{i=1}^m \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, i = 1, 2 \dots m$$

$$\alpha_i^{k+1} = 0 \Rightarrow y_i g(x_i) \geq 1$$

$$0 < \alpha_i^{k+1} < C \Rightarrow y_i g(x_i) = 1$$

$$\alpha_i^{k+1} = C \Rightarrow y_i g(x_i) \leq 1$$

7) 如果满足则结束, 返回 α^{k+1} , 否则转到步骤2)。




章节目录


- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归
- 核方法



支持向量回归



SVR使靠超平面最近的样本点之间的间隔最大




间隔最大？满足误差约束



支持向量回归

满足误差约束下间隔最大: $|y_i - (\mathbf{w}^T \mathbf{x}_i + b)| \leq \varepsilon, \quad i = 1, 2, \dots, N$




SVR的目的是：保证所有样本点在 ε 管道内的前提下，回归超平面 $f(\mathbf{x})$ 尽可能地平。




支持向量回归


ϵ 设置太小无法保证所有样本点都在 ϵ 管道内， ϵ 太大回归超平面会被一些异常点带偏。



ϵ 设得太小



ϵ 设大一点呢？



添加松弛变量




损失函数

不仅需要最大化间隔带，
还有最小化损失

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m l_{\epsilon}(f(x_i) - y_i)$$

允许间隔带外存在点，但
损失应尽可能的小



落入中间 2ϵ 间隔带的样本
不计算损失, 从而使得模型
获得稀疏性.



引入松弛变量SVR问题

原始问题

$$\begin{aligned} \min_{\mathbf{w}, b, \xi_i, \hat{\xi}_i} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m (\xi_i + \hat{\xi}_i) \\ \text{s.t.} \quad & y_i - \mathbf{w}^\top \phi(\mathbf{x}_i) - b \leq \epsilon + \xi_i, \\ & y_i - \mathbf{w}^\top \phi(\mathbf{x}_i) - b \geq -\epsilon - \hat{\xi}_i, \\ & \xi_i \geq 0, \hat{\xi}_i \geq 0, i = 1, 2, \dots, m. \end{aligned}$$

对偶问题

$$\begin{aligned} \min_{\alpha, \hat{\alpha}} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m (\alpha_i - \hat{\alpha}_i)(\alpha_j - \hat{\alpha}_j) \kappa(\mathbf{x}_i, \mathbf{x}_j) + \sum_{i=1}^m (\alpha_i(\epsilon - y_i) + \hat{\alpha}_i(\epsilon + y_i)) \\ \text{s.t.} \quad & \sum_{i=1}^m (\alpha_i - \hat{\alpha}_i) = 0, \\ & 0 \leq \alpha_i \leq C, 0 \leq \hat{\alpha}_i \leq C. \end{aligned}$$

预测

$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$$



章节目录

- 间隔与支持向量
 - 对偶问题
 - 核函数
 - 软间隔与正则化
 - 支持向量回归
 - 核方法
-



表示定理

支持向量机 $f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m \alpha_i y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$

支持向量回归 $f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$

结论: 无论是支持向量机还是支持向量回归, 学得模型总可以表示成核函数的线性组合.

更一般的结论(表示定理): 对于任意单调增函数 Ω 和任意非负损失函数 l , 优化问题

$$\min_{h \in \mathbb{H}} F(h) = \Omega(\|h\|_{\mathbb{H}}) + l(h(\mathbf{x}_1), \dots, h(\mathbf{x}_m))$$

的解总可以写为 $h^* = \sum_{i=1}^m \alpha_i \kappa(\cdot, \mathbf{x}_i)$



核线性判别分析

通过表示定理可以得到很多线性模型的“核化”版本

- 核SVM
- 核LDA
- 核PCA
-

核LDA：先将样本映射到高维特征空间，然后在此特征空间中做线性判别分析

$$\begin{aligned} \max_w J(w) &= \frac{w^\top S_b^\phi w}{w^\top S_w^\phi w} \\ &\downarrow \\ \max_\alpha J(\alpha) &= \frac{\alpha^\top M \alpha}{\alpha^\top N \alpha} \end{aligned} \quad h(x) = w^\top \phi(x) = \sum_{i=1}^m \alpha_i \kappa(x_i, x)$$



总结

支持向量机的“最大间隔”思想

对偶问题及其解的稀疏性

通过向高维空间映射解决线性不可分的问题

引入“软间隔”缓解特征空间中线性不可分的问题

将支持向量的思想应用到回归问题上得到支持向量回归

将核方法推广到其他学习模型



成熟的SVM软件包

LIBSVM

<http://www.csie.ntu.edu.tw/~cjlin/libsvm/>

LIBLINEAR

<http://www.csie.ntu.edu.tw/~cjlin/liblinear/>

SVM^{light}、SVM^{perf}、SVM^{struct}

http://svmlight.joachims.org/svm_struct.html

Pegasos

<http://www.cs.huji.ac.il/~shais/code/index.html>
